

Apprentissage Non Supervisé – Clustering

UP : Mathématiques

Année universitaire 2024-2025

Plan

Rappel : Types d'apprentissage et algorithmes

Notion du regroupement (Clustering)

Types de Clustering


Algorithme K-MEANS

- Comment fonctionne ?

- Quel est le nombre de clusters à choisir ?

Exemple d'application

Rappel: Types d'apprentissage et algorithmes



Notion du regroupement (Clustering)

Regrouper des éléments similaires, comme des livres, aide à mieux s'informer. On peut les classer par auteur, genre ou date de publication.

Notion du regroupement (Clustering)

Regrouper des éléments similaires, comme des livres, aide à mieux s'informer. On peut les classer par auteur, genre ou date de publication.

Cette organisation permet d'extraire plus d'informations et de créer de nouveaux groupes en combinant des critères pertinents.


Organisation des données en Machine Learning

En Machine Learning, organiser les données en groupes facilite leur compréhension. Deux approches principales existent :

Organisation des données en Machine Learning

En Machine Learning, organiser les données en groupes facilite leur compréhension. Deux approches principales existent :


- **Apprentissage supervisé** : Lorsque les données sont étiquetées, elles sont classées selon leurs labels.




Organisation des données en Machine Learning

En Machine Learning, organiser les données en groupes facilite leur compréhension. Deux approches principales existent :

- **Apprentissage supervisé** : Lorsque les données sont étiquetées, elles sont classées selon leurs labels.



- **Apprentissage non supervisé** : Lorsque les données ne sont pas étiquetées, elles sont regroupées en clusters homogènes partageant des caractéristiques communes.



Clustering et Applications

Le **clustering** est une méthode d'apprentissage non supervisée qui regroupe les données selon leurs similarités.

Clustering et Applications

Le **clustering** est une méthode d'apprentissage non supervisée qui regroupe les données selon leurs similarités.

Applications :

- ▶ **Segmentation des clients** : Regrouper les consommateurs aux comportements d'achat similaires.

Clustering et Applications

Le **clustering** est une méthode d'apprentissage non supervisée qui regroupe les données selon leurs similarités.

Applications :

- ▶ **Segmentation des clients** : Regrouper les consommateurs aux comportements d'achat similaires.
- ▶ **Analyse des réseaux sociaux** : Identifier des communautés aux intérêts communs.

Clustering et Applications

Le **clustering** est une méthode d'apprentissage non supervisée qui regroupe les données selon leurs similarités.

Applications :

- ▶ **Segmentation des clients** : Regrouper les consommateurs aux comportements d'achat similaires.
- ▶ **Analyse des réseaux sociaux** : Identifier des communautés aux intérêts communs.
- ▶ **Détection de fraudes** : Repérer des transactions ou comportements inhabituels.

Clustering et Applications

Le **clustering** est une méthode d'apprentissage non supervisée qui regroupe les données selon leurs similarités.

Applications :

- ▶ **Segmentation des clients** : Regrouper les consommateurs aux comportements d'achat similaires.
- ▶ **Analyse des réseaux sociaux** : Identifier des communautés aux intérêts communs.
- ▶ **Détection de fraudes** : Repérer des transactions ou comportements inhabituels.
- ▶ **Biologie** : Classer des gènes ou espèces selon leurs caractéristiques.

Clustering et Applications

Le **clustering** est une méthode d'apprentissage non supervisée qui regroupe les données selon leurs similarités.

Applications :

- ▶ **Segmentation des clients** : Regrouper les consommateurs aux comportements d'achat similaires.
- ▶ **Analyse des réseaux sociaux** : Identifier des communautés aux intérêts communs.
- ▶ **Détection de fraudes** : Repérer des transactions ou comportements inhabituels.
- ▶ **Biologie** : Classer des gènes ou espèces selon leurs caractéristiques.
- ▶ **Imagerie médicale** : Segmenter les images en différentes zones d'intérêt.

Types de Clustering

Clustering basé sur le centroïde

Types de Clustering

Clustering basé sur le centroïde

- ▶ Utilise des centroïdes pour représenter chaque cluster.

Types de Clustering

Clustering basé sur le centroïde

- ▶ Utilise des centroïdes pour représenter chaque cluster.
- ▶ L'algorithme **k-means** est un exemple populaire.

Types de Clustering

Clustering basé sur le centroïde

- ▶ Utilise des centroïdes pour représenter chaque cluster.
- ▶ L'algorithme **k-means** est un exemple populaire.

Clustering basé sur la densité

Types de Clustering

Clustering basé sur le centroïde

- ▶ Utilise des centroïdes pour représenter chaque cluster.
- ▶ L'algorithme **k-means** est un exemple populaire.

Clustering basé sur la densité

- ▶ Identifie des zones de haute densité de points de données et les regroupe.

Types de Clustering

Clustering basé sur le centroïde

- ▶ Utilise des centroïdes pour représenter chaque cluster.
- ▶ L'algorithme **k-means** est un exemple populaire.

Clustering basé sur la densité

- ▶ Identifie des zones de haute densité de points de données et les regroupe.
- ▶ **DBSCAN** est un algorithme couramment utilisé.

Types de Clustering

Clustering basé sur le centroïde

- ▶ Utilise des centroïdes pour représenter chaque cluster.
- ▶ L'algorithme **k-means** est un exemple populaire.

Clustering basé sur la densité

- ▶ Identifie des zones de haute densité de points de données et les regroupe.
- ▶ **DBSCAN** est un algorithme couramment utilisé.

Clustering hiérarchique

Types de Clustering

Clustering basé sur le centroïde

- ▶ Utilise des centroïdes pour représenter chaque cluster.
- ▶ L'algorithme **k-means** est un exemple populaire.

Clustering basé sur la densité

- ▶ Identifie des zones de haute densité de points de données et les regroupe.
- ▶ **DBSCAN** est un algorithme couramment utilisé.

Clustering hiérarchique

- ▶ Crée une hiérarchie de clusters, souvent représentée sous forme d'arbre.

Algorithme K-means

Définition

Algorithme K-means

Définition

- ▶ L'algorithme **K-means** est une méthode de clustering non supervisée.

Algorithme K-means

Définition

- ▶ L'algorithme **K-means** est une méthode de clustering non supervisée.
- ▶ Il vise à partitionner un ensemble de données en **K clusters**.

Algorithme K-means

Définition

- ▶ L'algorithme **K-means** est une méthode de clustering non supervisée.
- ▶ Il vise à partitionner un ensemble de données en **K clusters**.
- ▶ Chaque observation appartient au cluster avec le centroïde le plus proche.

Algorithme K-means

Définition

- ▶ L'algorithme **K-means** est une méthode de clustering non supervisée.
- ▶ Il vise à partitionner un ensemble de données en **K clusters**.
- ▶ Chaque observation appartient au cluster avec le centroïde le plus proche.

Choix du nombre de clusters (K)

Algorithme K-means

Définition

- ▶ L'algorithme **K-means** est une méthode de clustering non supervisée.
- ▶ Il vise à partitionner un ensemble de données en **K clusters**.
- ▶ Chaque observation appartient au cluster avec le centroïde le plus proche.

Choix du nombre de clusters (K)

- ▶ Le nombre de groupes (K) n'est pas connu à l'avance.

Algorithme K-means

Définition

- ▶ L'algorithme **K-means** est une méthode de clustering non supervisée.
- ▶ Il vise à partitionner un ensemble de données en **K clusters**.
- ▶ Chaque observation appartient au cluster avec le centroïde le plus proche.

Choix du nombre de clusters (K)

- ▶ Le nombre de groupes (K) n'est pas connu à l'avance.
- ▶ C'est au **Data Scientist** de le déterminer en fonction du jeu de données.

Algorithme K-means

Définition

- ▶ L'algorithme **K-means** est une méthode de clustering non supervisée.
- ▶ Il vise à partitionner un ensemble de données en **K clusters**.
- ▶ Chaque observation appartient au cluster avec le centroïde le plus proche.


Choix du nombre de clusters (K)

- ▶ Le nombre de groupes (K) n'est pas connu à l'avance.
- ▶ C'est au **Data Scientist** de le déterminer en fonction du jeu de données.
- ▶ Il doit estimer par lui-même le nombre de groupes présents dans les données.

Comment fonctionne l'algorithme K-means ?

Cas d'usage classique : segmentation de clients

L'algorithme K-means permet de segmenter un ensemble de clients en k groupes, en fonction de leurs caractéristiques. Prenons un exemple où nous voulons segmenter les clients d'une Banque en fonction de deux variables : l'âge et le revenu.



Cas d'usage classique : segmentation de clients

Visuellement, les clients peuvent se séparer en 4 groupes distincts :

- ▶ **Groupe 1 (en violet)** : Clients dans leurs vingtaines, ayant un revenu annuel élevé (entre 120k et 140k).
- ▶ **Groupe 2 (en orange)** : Clients dans leurs trentaines/quarantaines, ayant un revenu annuel moyen (entre 80k et 120k).
- ▶ **Groupe 3 (en bleu foncé)** : Clients dont l'âge varie entre 40 et 60 ans, ayant un revenu annuel moyen (entre 40k et 100k).
- ▶ **Groupe 4 (en bleu clair)** : Clients dont l'âge varie entre 80 et 100 ans, ayant un revenu annuel bas (entre 0k et 60k).

La banque peut maintenant préparer **quatre stratégies** ou **offres différentes**, une pour chaque groupe, au lieu de créer des stratégies différentes pour chaque client. Cela réduira l'effort ainsi que le temps.

Mais comment les groupes sont-ils choisis réellement ?

La banque peut maintenant préparer **quatre stratégies** ou **offres différentes**, une pour chaque groupe, au lieu de créer des stratégies différentes pour chaque client. Cela réduira l'effort ainsi que le temps.

Mais comment les groupes sont-ils choisis réellement ?

Comment savoir quel élément à mettre dans tel et tel groupe ?

La banque peut maintenant préparer **quatre stratégies** ou **offres différentes**, une pour chaque groupe, au lieu de créer des stratégies différentes pour chaque client. Cela réduira l'effort ainsi que le temps.


Mais comment les groupes sont-ils choisis réellement ?

Comment savoir quel élément à mettre dans tel et tel groupe ?

Comment choisir le nombre de groupes optimal pour son jeu de données ?

Détails de l'algorithme k-means

Prenons un exemple simple avec les données réparties sous cette configuration.



Détails de l'algorithme k-means


- ▶ **Étape 1 : Initialisation**
 - ▶ Choisir k centres de clusters aléatoires.

Détails de l'algorithme k-means

► Étape 1 : Initialisation

- Choisir k centres de clusters aléatoires.

Visuellement, un humain peut distinguer **trois groupes $k=3$** ,
mais la machine ne voit que des *points* sans signification.



Détails de l'algorithme k-means


▶ Étape 2 : Affectation des points

- ▶ Chaque client est affecté au cluster dont le centre est le plus proche.

Détails de l'algorithme k-means

► Étape 2 : Affectation des points

- Chaque client est affecté au cluster dont le centre est le plus proche. L'algorithme passe par les points de données un par un, en mesurant la distance entre chaque point par rapport aux trois centroïdes (A, B et C). Par exemple, le point n°21 appartiendra au groupe de A car il est plus proche au centroïde A que C et B.



Détails de l'algorithme k-means

▶ **Étape 3 : Mise à jour des centres**

- ▶ Recalculer les nouveaux centres des clusters en prenant la moyenne des clients dans chaque cluster.

Détails de l'algorithme k-means

► Étape 3 : Mise à jour des centres

- Recalculer les nouveaux centres des clusters en prenant la moyenne des clients dans chaque cluster.

Il faut donc recalculer les 3 nouveaux centroïdes qui seront les centres de gravité de chaque groupe calculé dans l'étape précédente

Détails de l'algorithme k-means

- ▶ **Étape 4 : Répétition**


- ▶ Répéter les étapes 2 et 3 jusqu'à convergence.

Détails de l'algorithme k-means

► Étape 4 : Répétition

- Répéter les étapes 2 et 3 jusqu'à convergence.

On répète ces étapes jusqu'à ce que les nouveaux centroïdes soient stabilisés, et ne changent plus de groupe.



Quelle métrique utiliser pour évaluer la distance entre les points et les centroïdes ?

Pour pouvoir regrouper un jeu de données en k groupes distincts, l'algorithme k-means a besoin d'un moyen pour **comparer le degré de similarité** entre les différentes observations.

Quelle métrique utiliser pour évaluer la distance entre les points et les centroïdes ?

Pour pouvoir regrouper un jeu de données en k groupes distincts, l'algorithme k-means a besoin d'un moyen pour **comparer le degré de similarité** entre les différentes observations.

L'algorithme des k-means fait généralement intervenir la **distance euclidienne**. Soient deux groupes d'éléments $p = (x_1, x_2, \dots, x_n)$ et $q = (y_1, y_2, \dots, y_n)$, alors la distance d entre les points p et q se calcule avec la formule suivante :

$$d(p, q) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Quel est le nombre de clusters à choisir ?

- ▶ lorsque les données sont nombreuses et sans structure apparente, le choix de k devient difficile.

Quel est le nombre de clusters à choisir ?

- ▶ lorsque les données sont nombreuses et sans structure apparente, le choix de k devient difficile.
- ▶ il existe alors deux méthodes empiriques pour estimer une valeur optimale de k .

Méthode du coude


- ▶ Cette méthode consiste à exécuter l'algorithme k-means avec différentes valeurs de k .

Méthode du coude

- ▶ Cette méthode consiste à exécuter l'algorithme k-means avec différentes valeurs de k .
- ▶ On calcule la distance moyenne entre les points et leurs centroïdes au carré, appelée **WSS (within sum of squares)**.

Méthode du coude


- ▶ Cette méthode consiste à exécuter l'algorithme k-means avec différentes valeurs de k .
- ▶ On calcule la distance moyenne entre les points et leurs centroïdes au carré, appelée **WSS (within sum of squares)**.
- ▶ On trace un graphique où k est en fonction de la WSS.



- ▶ La courbe obtenue présente un point d'inflexion appelé "le coude".

- ▶ La courbe obtenue présente un point d'inflexion appelé "le coude".
- ▶ Après ce point, l'augmentation de k réduit peu la WSS, indiquant que l'ajout de clusters supplémentaires n'améliore plus significativement la segmentation.

- ▶ La courbe obtenue présente un point d'inflexion appelé "le coude".
- ▶ Après ce point, l'augmentation de k réduit peu la WSS, indiquant que l'ajout de clusters supplémentaires n'améliore plus significativement la segmentation.
- ▶ La valeur optimale de k est donc située à ce coude.



Méthode de silhouette

- ▶ Cette méthode évalue la qualité d'un clustering en mesurant la cohésion des points dans un cluster et leur séparation avec les autres clusters.

Méthode de silhouette

- ▶ Cette méthode évalue la qualité d'un clustering en mesurant la cohésion des points dans un cluster et leur séparation avec les autres clusters.
- ▶ Pour chaque point, on calcule :
 - ▶ La **distance moyenne** du point avec tous les autres points du même cluster.

Méthode de silhouette

- ▶ Cette méthode évalue la qualité d'un clustering en mesurant la cohésion des points dans un cluster et leur séparation avec les autres clusters.
- ▶ Pour chaque point, on calcule :
 - ▶ La **distance moyenne** du point avec tous les autres points du même cluster.
 - ▶ La **distance moyenne** du point avec les points du cluster le plus proche.

- Le coefficient de silhouette pour un point i est défini par la formule :

$$s(i) = \frac{b(i) - a(i)}{\max(b(i), a(i))}$$

- ▶ Le coefficient de silhouette pour un point i est défini par la formule :

$$s(i) = \frac{b(i) - a(i)}{\max(b(i), a(i))}$$

où :

- ▶ $a(i)$ est la distance moyenne entre le point i et les autres points de son cluster.

- ▶ Le coefficient de silhouette pour un point i est défini par la formule :

$$s(i) = \frac{b(i) - a(i)}{\max(b(i), a(i))}$$

où :

- ▶ $a(i)$ est la distance moyenne entre le point i et les autres points de son cluster.
- ▶ $b(i)$ est la distance moyenne entre le point i et le cluster voisin le plus proche.

- ▶ On teste plusieurs valeurs de k et on calcule le **coefficient de silhouette moyen** pour chaque valeur.

- ▶ On teste plusieurs valeurs de k et on calcule le **coefficient de silhouette moyen** pour chaque valeur.
- ▶ La valeur optimale de k correspond à celle maximisant ce coefficient.

- ▶ On teste plusieurs valeurs de k et on calcule le **coefficient de silhouette moyen** pour chaque valeur.
- ▶ La valeur optimale de k correspond à celle maximisant ce coefficient.
- ▶ Un coefficient élevé indique des clusters bien séparés et homogènes.



Exemple d'application

Cas bancaire: Segmentation de clients en fonction de l'âge et du revenu annuel.

Exemple d'application

Cas bancaire: Segmentation de clients en fonction de l'âge et du revenu annuel.

Voici un jeu de données représentant les 8 clients bancaires avec leur âge (en années) et revenu annuel (en milliers d'euros) :

Client	Âge (années)	Revenu (milliers €)
1	25	30
2	45	50
3	35	60
4	50	100
5	29	80
6	55	120
7	41	90
8	60	150

Etape 1

- ▶ L'algorithme K-Means commence par l'initialisation des centroïdes. Ici, nous choisissons aléatoirement 3 points comme centroïdes initiaux :
 - ▶ $C_1 = (25, 30)$ (Client 1)
 - ▶ $C_2 = (50, 100)$ (Client 4)
 - ▶ $C_3 = (60, 150)$ (Client 8)
- ▶ Nous allons maintenant assigner chaque client à son centroïde le plus proche.

Eatpe 2

Pour chaque client, nous calculons la distance euclidienne entre le client et chaque centroïde :

$$\text{Distance} = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}$$

La table suivante montre les distances entre chaque client et les trois centroïdes, ainsi que l'assignation au centroïde le plus proche :

Client	Âge	Revenu	Distance à C_1	Distance à C_2	Distance à C_3	Cluster Assigné
1	25	30	0.00	77.46	144.62	C1
2	45	50	29.15	77.46	119.49	C1
3	35	60	30.41	50.91	111.80	C1
4	50	100	77.46	0.00	103.08	C2
5	29	80	50.91	29.15	91.92	C2
6	55	120	103.08	29.15	36.05	C3
7	41	90	60.16	15.13	77.46	C2
8	60	150	144.62	103.08	0.00	C3

Etape 2

On affecte les points aux centroïdes le plus proche:

Etape 2

On affecte les points aux centroïdes le plus proche:

- ▶ Cluster 1 (proche de C_1) : Client 1, Client 2, Client 3
- ▶ Cluster 2 (proche de C_2) : Client 4, Client 5, Client 7
- ▶ Cluster 3 (proche de C_3) : Client 6, Client 8

Etape 3

Nous recalculons les centroïdes de chaque cluster en prenant la moyenne des points assignés à chaque cluster :

Nouveau centroïde C_1 :

$$C_1 = \left(\frac{25 + 45 + 35}{3}, \frac{30 + 50 + 60}{3} \right) = (35, 46.67)$$

Nouveau centroïde C_2 :

$$C_2 = \left(\frac{50 + 29 + 41}{3}, \frac{100 + 80 + 90}{3} \right) = (40, 90)$$

Nouveau centroïde C_3 :

$$C_3 = \left(\frac{55 + 60}{2}, \frac{120 + 150}{2} \right) = (57.5, 135)$$

Etape 4

- ▶ Avec ces nouveaux centroïdes , on répète l'attribution des points aux clusters comme précédemment.

Etape 4

- ▶ Avec ces nouveaux centroïdes , on répète l'attribution des points aux clusters comme précédemment.
- ▶ On calcule les distances pour chaque point et réattribue les clusters, Cette étape se répète jusqu'à la convergence

Etape 4

- ▶ Avec ces nouveaux centroïdes , on répète l'attribution des points aux clusters comme précédemment.
- ▶ On calcule les distances pour chaque point et réattribue les clusters, Cette étape se répète jusqu'à la convergence

Client	Âge	Revenu	Distance à C_1	Distance à C_2	Distance à C_3	Cluster Assigné
1	25	30	20.62	60.83	128.29	C1
2	45	50	12.08	47.17	115.20	C1
3	35	60	13.00	30.00	101.24	C1
4	50	100	57.35	10.00	95.89	C2
5	29	80	35.00	13.00	88.23	C2
6	55	120	88.23	30.00	16.00	C3
7	41	90	43.00	0.00	76.16	C2
8	60	150	130.38	76.16	16.00	C3

Etape 4

- ▶ Les points sont à nouveau regroupés selon la proximité des centroïdes recalculés.

Etape 4

- ▶ Les points sont à nouveau regroupés selon la proximité des centroïdes recalculés.
- ▶ Les clusters restent stables, et les points sont assignés de manière similaire à la première attribution.

Etape 4

- ▶ Les points sont à nouveau regroupés selon la proximité des centroïdes recalculés.
- ▶ Les clusters restent stables, et les points sont assignés de manière similaire à la première attribution.
- ▶ Après quelques itérations, on obtient:
 - ▶ Cluster 1 : Client 1, Client 2, Client 3
 - ▶ Cluster 2 : Client 4, Client 5, Client 7
 - ▶ Cluster 3 : Client 6, Client 8

Avantages et Inconvénients de K-Means

Avantages	Inconvénients
L'algorithme est simple et non hiérarchique, nécessitant peu de temps d'exécution. Rapide et efficace en termes de coûts de calcul. Solution adaptée aux données volumineuses.	Ne peut être exécuté qu'avec des données numériques, ce qui limite son utilisation avec d'autres types de données. Déconseillé pour des données non numériques.

Conclusion

En résumé, pour des jeux de données de **grande dimension**, les modèles de **Machine Learning** nécessitent des **ensembles d'entraînement étendus**.

Conclusion

En résumé, pour des jeux de données de **grande dimension**, les modèles de **Machine Learning** nécessitent des **ensembles d'entraînement étendus**. Les **K-means**, malgré l'absence de **garantie de convergence**, restent un choix privilégié grâce à leur **simplicité**, **rapidité** et **faible coût en calcul**.

Conclusion

En résumé, pour des jeux de données de **grande dimension**, les modèles de **Machine Learning** nécessitent des **ensembles d'entraînement étendus**. Les **K-means**, malgré l'absence de **garantie de convergence**, restent un choix privilégié grâce à leur **simplicité**, **rapidité** et **faible coût en calcul**. Ils sont utilisés dans des domaines variés tels que **l'imagerie médicale** et la **segmentation des couleurs**,

Conclusion

En résumé, pour des jeux de données de **grande dimension**, les modèles de **Machine Learning** nécessitent des **ensembles d'entraînement étendus**. Les **K-means**, malgré l'absence de **garantie de convergence**, restent un choix privilégié grâce à leur **simplicité**, **rapidité** et **faible coût en calcul**. Ils sont utilisés dans des domaines variés tels que **l'imagerie médicale** et la **segmentation des couleurs**, bien qu'il faille être **vigilant** sur les risques d'**instabilité** dans les résultats.